



T3 · INTEROPERABILIDADE E DADOS EM SAÚDE

O tesouro de dados do SUS

Como transformar os dados públicos do DATASUS em painéis de gestão — apostila de divulgação científica baseada na publicação *Building Health Management Dashboards with DATASUS Public Data* (UFF · IEEE INDUSCON).

Apostila de divulgação científica · IND-02

Coleção TED 77/2024 · Transformação Digital do SUS



MINISTÉRIO DA
SAÚDE



Ficha técnica

Produto	Apostila de divulgação científica — Coleção TED 77/2024 (versão didática de publicação do acervo).
Publicação original	<i>Building Health Management Dashboards with DATASUS Public Data</i> — IEEE INDUSCON.
Autores	Luiz Felipe Alves; Ricardo Alexandre da Silva; Diego Zoracky W. Oliveira; Luiz Eduardo de M. Rodrigues; Flávio L. Seixas; Alexandre Beraldi dos Santos — Universidade Federal Fluminense (UFF).
Tema no acervo	T3 — Interoperabilidade e dados em saúde.
Instrumento	TED nº 77/2024 (proc. 00030420240093-003430) — Ministério da Saúde (SEIDIGI) × UFF · Fundação Euclides da Cunha (FEC).
Público-alvo	Gestores e profissionais do SUS, analistas de dados, estudantes e jornalistas de dados.
Produtos irmãos	Resumo didático · Fichamento DMAIC · Vídeo (3 min) · Podcast · Infográfico · Base de dados aberta · Painel interativo — disponíveis no portal do projeto.
Versão	1.0 — 2026. Material elaborado com apoio de inteligência artificial e revisão técnica; números auditados contra o texto-fonte e a base de dados aberta do projeto.

Os dados de internações citados nesta apostila provêm da base aberta DS-01 do projeto (SIH/SUS · DATASUS, competências 2025-01 a 2025-12, estado do Rio de Janeiro), disponível em github.com/RaulAraujoSilva/ted77-sih-rj-dados-abertos.

Sumário

Apresentação — por que este tema importa	4
Módulo 1 — O tesouro: o acervo de dados do DATASUS	5
Módulo 2 — O problema: sistemas que não conversam	8
Módulo 3 — O caminho: um pipeline de engenharia de dados	10
Módulo 4 — O resultado: painéis, impacto e aplicação no SUS	13
Síntese do percurso	16
Glossário	17
Referências	18

Como usar este material. Leia os módulos na sequência para construir o conceito; teste-se com as questões *Pratique agora* (gabarito comentado ao final de cada box); explore o **painel interativo** e a **base de dados aberta** do projeto para ver os conceitos funcionando com dados reais. As caixas sinalizam *Objetivos*, *Conceitos-chave*, *Base legal*, *Na prática (SUS)*, *Atenção*, *Pratique agora* e *Para se aprofundar*.

Apresentação



Mapa do percurso — Do acervo bruto do DATASUS ao painel de gestão: os quatro módulos desta apostila.

O Sistema Único de Saúde atende **mais de 75% da população brasileira** — e cada atendimento vira registro. Internações, consultas, nascimentos, vacinas e óbitos alimentam, há décadas, um dos maiores repositórios públicos de dados de saúde do mundo: o **DATASUS**. Esse acervo poderia responder, em minutos, a perguntas essenciais da gestão — onde a demanda cresce? que doenças mais internam? quanto custa o cuidado? — mas, na prática, ele permanece subutilizado.

A razão é estrutural: os sistemas que produzem esses dados nasceram separados, cada um para uma finalidade administrativa ou de vigilância, com formatos e códigos próprios e **sem um identificador único de paciente** que os conecte. A publicação que inspira esta apostila — produzida por pesquisadores da UFF no âmbito do TED 77/2024 — apresenta um caminho prático para superar essa fragmentação: um **pipeline de engenharia de dados** que extrai, limpa, vincula e organiza os dados públicos até transformá-los em **painéis interativos de gestão**.

Esta apostila traduz esse percurso técnico em linguagem acessível, em quatro módulos. E vai além do papel: o projeto aplicou a metodologia do artigo e publicou uma **base de dados aberta** com as internações do SUS no Rio de Janeiro em 2025 e um **painel interativo público** — você pode explorar os dois enquanto estuda.

Objetivos de aprendizagem

Ao concluir o estudo desta apostila, espera-se que você seja capaz de:

1. Reconhecer os principais sistemas de informação do DATASUS e o que cada um registra.

2. Explicar por que a ausência de um identificador único de paciente fragmenta a análise no SUS.

3. Descrever as quatro etapas do pipeline: extração, limpeza, vinculação probabilística e organização analítica (OLAP).

4. Diferenciar o TabNet das ferramentas modernas de Business Intelligence.

5. Interpretar indicadores básicos de internação (volume, valor, permanência, mortalidade) em um painel.

6. Localizar e reutilizar dados abertos do projeto na sua realidade de trabalho.

COMO ESTUDAR

Leia cada módulo na sequência. Os boxes destacam **conceitos-chave**, a **base normativa** aplicável e situações **na prática (SUS)**. Ao final, use a síntese e o glossário para revisar — e abra o painel interativo do projeto para explorar os dados de verdade.

MÓDULO 1 · 1 de 4

O tesouro: o acervo de dados do DATASUS

O que é o DATASUS, quais sistemas o compõem e por que esse acervo é único no mundo.

🎯 AO FINAL DESTES MÓDULO, VOCÊ SERÁ CAPAZ DE...

- Situar o DATASUS como departamento de informática do SUS e repositório nacional de dados de saúde;
- Identificar os **seis sistemas nacionais** citados na publicação: SIH, SIA, CNES, SIM, SINASC e SINAN — além de SI-PNI e e-SUS AB;
- Reconhecer a escala do acervo e o seu potencial para a gestão e a pesquisa.




Figura 1.1 — O ecossistema DATASUS: cada sistema nacional registra uma dimensão do cuidado em saúde.

1.1 Um repositório com a cara do SUS

O **DATASUS** é o departamento de informática do Sistema Único de Saúde. Criado para dar suporte tecnológico ao SUS, ele acabou se tornando o guardião de um patrimônio informacional gigantesco: os registros administrativos e epidemiológicos de um sistema de saúde que atende

mais de três quartos da população do país. Poucos países no mundo dispõem de um acervo público com essa cobertura populacional e essa profundidade histórica.

Cada contato do cidadão com o SUS deixa um rastro de dados em um sistema específico. A publicação que estudamos destaca seis deles:

Sistema	O que registra
SIH/SUS	Internações hospitalares — por meio da AIH (Autorização de Internação Hospitalar), com diagnóstico, procedimentos, permanência, valores e desfecho.
SIA/SUS	Atendimentos ambulatoriais — consultas, exames e procedimentos realizados fora da internação.
CNES	Cadastro Nacional de Estabelecimentos de Saúde — hospitais, UBS, clínicas, leitos, equipamentos e profissionais.
SIM	Sistema de Informações sobre Mortalidade — declarações de óbito e causas de morte.
SINASC	Sistema de Informações sobre Nascidos Vivos — nascimentos e condições do parto.
SINAN	Sistema de Agravos de Notificação — doenças e agravos de notificação compulsória (dengue, tuberculose etc.).

A esses seis somam-se outros conjuntos citados na publicação, como o **SI-PNI** (imunizações), o **e-SUS AB** (atenção primária) e os dados de financiamento. Juntos, eles oferecem uma visão longitudinal — ao longo do tempo — do panorama de saúde pública do Brasil.

CONCEITO-CHAVE

Dado administrativo é o registro gerado como subproduto da operação do sistema de saúde (faturamento, cadastro, notificação) — diferente do dado coletado para pesquisa. A grande sacada da publicação é mostrar que, bem tratados, os dados administrativos do DATASUS viram **inteligência de gestão** sem custo adicional de coleta.

BASE NORMATIVA

Os arquivos usados nesta apostila são **públicos e de disseminação oficial** do Ministério da Saúde, distribuídos pelo DATASUS em formato anonimizado. O tratamento de dados pessoais em saúde — quando há identificação — submete-se à **Lei Geral de Proteção de Dados (Lei nº 13.709/2018)**, que admite o uso para tutela da saúde e para políticas públicas, com salvaguardas.

 PRATIQUE AGORA · M1Q1

Uma secretaria municipal quer saber quantos partos de residentes do município ocorreram no último ano e em quais hospitais. Quais sistemas do DATASUS respondem melhor a essas duas perguntas, respectivamente?

- a. SIM e SINAN.
- b. SINASC e CNES.
- c. SIA e SIM.
- d. SINAN e e-SUS AB.

Gabarito: B. O **SINASC** registra os nascidos vivos (partos), e o **CNES** identifica os estabelecimentos de saúde. O **SIM** trata de mortalidade; o **SINAN**, de doenças de notificação; o **SIA**, de atendimentos ambulatoriais.

 EM RESUMO · MÓDULO 1

- O DATASUS reúne um dos maiores repositórios públicos de dados de saúde do mundo;
- SIH, SIA, CNES, SIM, SINASC e SINAN registram, cada um, uma dimensão do cuidado;
- São dados administrativos: gerados pela própria operação do SUS, sem custo extra de coleta;
- A cobertura é nacional — o SUS atende mais de 75% da população brasileira.

 PARA SE APROFUNDAR

BRASIL. Ministério da Saúde. **DATASUS — Departamento de Informática do SUS**. Portal oficial: datasus.saude.gov.br.

Navegue pela seção de "Transferência de Arquivos" para conhecer os conjuntos disponíveis — são os mesmos arquivos usados pelo pipeline desta apostila.

MÓDULO 2 · 2 de 4

O problema: sistemas que não conversam

Fragmentação, ausência de identificador único e os limites das tabelas estáticas.

🎯 AO FINAL DESTES MÓDULO, VOCÊ SERÁ CAPAZ DE...

- Explicar por que os sistemas do DATASUS não interoperam nativamente;
- Descrever as consequências da ausência de um **identificador único de paciente**;
- Reconhecer os limites do TabNet e a necessidade de ferramentas mais interativas.

2.1 Silos de dados

Os sistemas do módulo anterior foram desenvolvidos de forma **independente**, cada um para atender a uma finalidade específica — faturamento, vigilância, cadastro. O resultado, como aponta a publicação, são **silos de dados**: formatos diferentes, códigos diferentes e nenhuma chave comum que conecte os registros de uma mesma pessoa.

O exemplo mais eloquente está no par SIH–SIA: os dois registram episódios de cuidado de forma independente, para fins de ressarcimento, mas **não compartilham chaves** que permitam ligar um atendimento ambulatorial à internação que veio depois. A trajetória do paciente — justamente o que interessa à coordenação do cuidado — se perde entre os sistemas.

⚠️ ATENÇÃO

Sem identificador único de paciente, **não é possível reconstruir automaticamente a linha do cuidado**. Qualquer análise que cruze sistemas (por exemplo, "quantos pacientes atendidos no ambulatório foram internados em 30 dias?") exige técnicas estatísticas de vinculação de registros — tema do Módulo 3.

2.2 O TabNet e os limites da tabela estática

Historicamente, o Ministério da Saúde ofereceu o **TabNet** — um tabulador web de código aberto que permite consultar as bases do DATASUS e gerar tabelas-resumo com filtros de ano, região ou causa. A publicação reconhece o papel histórico do TabNet na **democratização do acesso** aos dados públicos de saúde.

Mas o instrumento tem limites claros: entrega **tabelas estáticas e gráficos simples**, não integra múltiplas fontes e não oferece a experiência interativa — filtros dinâmicos, detalhamento progressivo, cruzamentos em tempo real — de que o gestor modernamente precisa. É a diferença entre *consultar um número* e *explorar um fenômeno*.

✚ NA PRÁTICA (SUS)

Pense na pergunta: "as internações por causas respiratórias estão subindo na minha região?". No TabNet, ela exige montar e baixar várias tabelas, mês a mês, e consolidá-las manualmente. Em um painel interativo, é **um clique no filtro** — e a série temporal aparece na hora, pronta para a reunião de gestão.

✂ PRATIQUE AGORA · M2Q1

Sobre a fragmentação dos dados no DATASUS, assinale a alternativa correta:

- Os sistemas compartilham um identificador único de paciente, mas os formatos de arquivo são incompatíveis.
- A fragmentação decorre de os sistemas terem sido criados de forma independente, sem chaves comuns entre eles.
- O TabNet resolve a fragmentação ao integrar automaticamente SIH, SIA e SIM.
- A fragmentação impede qualquer uso analítico dos dados do DATASUS.

Gabarito: B. Os sistemas nasceram separados, cada um com formato e códigos próprios e **sem identificador único** (descarta A). O TabNet apenas tabula cada base isoladamente (descarta C). E a fragmentação dificulta — mas não impede — o uso analítico: o Módulo 3 mostra exatamente como superá-la (descarta D).

☑ EM RESUMO · MÓDULO 2

- Os sistemas do DATASUS são silos: formatos e códigos próprios, sem chave comum;
- Não existe identificador único de paciente — a trajetória do cuidado se fragmenta;
- O TabNet democratizou o acesso, mas entrega apenas tabelas estáticas;
- Gestão moderna pede interatividade: filtros, séries, detalhamento progressivo.

📖 PARA SE APROFUNDAR

ALI, M. S. et al. **Administrative data linkage in Brazil: potentials for health technology assessment.** *Frontiers in Pharmacology*, v. 10, p. 984, 2019.

Referência citada na publicação: panorama do potencial (e dos desafios) da vinculação de bases administrativas brasileiras para avaliação de tecnologias em saúde.

MÓDULO 3 · 3 de 4

O caminho: um pipeline de engenharia de dados

Extração, limpeza, vinculação probabilística e organização analítica — as quatro etapas para destrancar o acervo.

🎯 AO FINAL DESTA MÓDULO, VOCÊ SERÁ CAPAZ DE...

- Descrever as quatro etapas do pipeline proposto na publicação;
- Explicar o papel de ferramentas abertas como o **PySUS** na extração;
- Compreender, em nível conceitual, a **vinculação probabilística de registros**;
- Definir o que é um armazém analítico organizado em **fatos e dimensões (OLAP)**.




Figura 3.1 — O pipeline em quatro estações: da extração nos servidores oficiais ao painel de BI.

3.1 Etapa 1 — Extração programática

Os arquivos públicos do DATASUS são distribuídos em formatos como DBF, CSV e TXT, por portais oficiais e servidores FTP. A extração manual, arquivo por arquivo, é trabalhosa e sujeita a erro. A publicação destaca as ferramentas abertas que **automatizam** esse acesso: o pacote Python **PySUS**

e os pacotes R *Datasus* e *Microdatasus*, que baixam os dados diretamente e já realizam transformações iniciais — como interpretar arquivos de largura fixa e juntar bases estaduais.

NA PRÁTICA (SUS)

O PySUS é **gratuito e de código aberto** (github.com/AlertaDengue/PySUS). Com poucas linhas de código, uma equipe estadual baixa todos os meses de internações (arquivos "RD" do SIH) da sua UF — foi exatamente assim que a base aberta deste projeto reuniu as internações do RJ em 2025.

3.2 Etapa 2 — Limpeza e padronização

Dados brutos chegam com inconsistências: textos sem padrão, códigos divergentes, duplicidades, valores extremos ou ausentes. A limpeza envolve **normalizar textos, mapear códigos** (como o CID-10, a classificação internacional de doenças, e os códigos de procedimento), **calcular atributos derivados** e **validar registros**. É o trabalho invisível que garante a *integridade referencial* — a confiança de que os números batem entre as tabelas.

3.3 Etapa 3 — Vinculação probabilística de registros

Aqui está o passo metodologicamente mais sofisticado. Na ausência do identificador único, a estatística reconecta os registros: modelos de **record linkage** — a publicação cita o clássico modelo de **Fellegi-Sunter** — comparam atributos parciais como **nome, data de nascimento e localização geográfica** e estimam a probabilidade de dois registros pertencerem à mesma pessoa.

Não é teoria distante: a técnica já foi aplicada no Brasil a **centenas de milhões de registros**, integrando SIH, SIA/APAC, SIM e SINAN, com projetos que avançaram ainda mais e transformaram os dados para o modelo internacional **OMOP**, ganhando interoperabilidade com pesquisas do mundo inteiro.

CONCEITO-CHAVE

Vinculação probabilística (record linkage) é o conjunto de técnicas estatísticas que decide se dois registros, em bases diferentes e sem chave comum, referem-se à mesma pessoa — ponderando concordâncias e discordâncias entre campos como nome, nascimento e endereço.

3.4 Etapa 4 — Armazém analítico e OLAP

Integrados e limpos, os dados são carregados em **armazéns analíticos** (data warehouses) — de bancos relacionais a plataformas em nuvem como Hadoop e BigQuery — organizados em **esquemas de fatos e dimensões**. Essa arquitetura, chamada **OLAP** (processamento analítico on-line), é o que permite responder em segundos a perguntas que cruzam vários ângulos: internações *por município, por mês, por especialidade, por diagnóstico*. Particionamento e indexação garantem desempenho mesmo com dezenas de milhões de registros de vários anos.

CONCEITO-CHAVE

No modelo dimensional, a **tabela fato** guarda os eventos mensuráveis (cada internação, com valor e permanência) e as **dimensões** guardam os ângulos de análise (tempo, lugar, especialidade, diagnóstico). O "cubo" OLAP é essa estrutura pronta para fatiar e cruzar.

PRATIQUE AGORA · M3Q1

Uma equipe precisa ligar registros do SIH e do SIM para estudar óbitos após a alta hospitalar. Não há identificador comum entre as bases. A solução tecnicamente adequada, segundo a publicação, é:

- Descartar o estudo, pois sem chave única a ligação é impossível.
- Usar vinculação probabilística (ex.: Fellegi-Sunter) sobre nome, data de nascimento e localização.
- Comparar manualmente os registros, paciente por paciente.
- Usar o TabNet, que integra as duas bases automaticamente.

Gabarito: B. É exatamente o cenário do *record linkage* probabilístico — técnica já aplicada a centenas de milhões de registros no Brasil. A comparação manual (C) não escala; o TabNet (D) tabula bases isoladas; e a impossibilidade (A) é desmentida pela literatura citada na publicação.

PRATIQUE AGORA · M3Q2

Associe corretamente a etapa do pipeline à sua função:

- Extração → eliminar duplicidades; Limpeza → baixar arquivos do FTP.
- Vinculação → organizar fatos e dimensões; OLAP → reconectar registros de uma pessoa.
- Extração → baixar os arquivos oficiais; Limpeza → padronizar códigos e tratar inconsistências; Vinculação → reconectar registros; OLAP → organizar para análise multidimensional.
- Limpeza → estimar probabilidade de dois registros serem da mesma pessoa.

Gabarito: C. A sequência correta do pipeline: **extração** (PySUS/FTP) → **limpeza** (CID-10, duplicidades, ausentes) → **vinculação** (Fellegi-Sunter) → **OLAP/BI** (fatos e dimensões prontos para o painel).

EM RESUMO · MÓDULO 3

- Extração: ferramentas abertas (PySUS, Datasus/Microdatasus em R) baixam os arquivos oficiais;
- Limpeza: padronização de códigos (CID-10), duplicidades, ausentes — integridade referencial;
- Vinculação probabilística reconecta registros sem chave comum — já aplicada a centenas de milhões de registros no Brasil, com convergência ao modelo OMOP;
- OLAP organiza fatos e dimensões para análises rápidas e multidimensionais.

 PARA SE APROFUNDAR

ICHIHARA, M. Y.; ALMEIDA, B.; BARRETO, M. L. **CIDACS: Brazil's Center for Data and Knowledge Integration for Health**. International Journal of Population Data Science, v. 6, n. 1, 2021.

Citada na publicação: o CIDACS/Fiocruz é a referência brasileira em vinculação de bases populacionais em escala — vale conhecer o desenho institucional.

MÓDULO 4 · 4 de 4

O resultado: painéis, impacto e aplicação no SUS

Da arquitetura ao painel interativo — e o que muda para o gestor, o pesquisador e o cidadão.

🎯 AO FINAL DESTES MÓDULO, VOCÊ SERÁ CAPAZ DE...

- Explicar o que um painel de BI agrega em relação às tabelas estáticas;
- Interpretar os indicadores básicos de internação no painel do projeto;
- Apontar a agenda de futuro da publicação: nuvem, padrões internacionais e IA.

4.1 Do cubo ao painel

Com o armazém analítico pronto, ferramentas de **Business Intelligence** conectam-se aos dados e entregam **painéis interativos**: visualizações com filtros, cruzamento dinâmico e *drill-down* — o detalhamento progressivo do estado ao município, do ano ao mês, do capítulo de diagnóstico à causa específica. O ganho central, nas palavras da publicação: partes interessadas conseguem **detectar tendências — como surtos de doenças ou mudanças no uso dos serviços — em minutos, e não em dias**.




Figura 4.1 — O painel interativo do projeto, construído com a metodologia da publicação sobre dados reais do SIH/SUS (RJ, 2025). Fonte: elaboração própria, dados DATASUS.

4.2 O caso real do projeto: SIH-RJ 2025

Para demonstrar a metodologia, este projeto de divulgação científica percorreu o pipeline completo com dados reais e publicou o resultado em formato aberto. Os números de 2025, no estado do Rio de Janeiro:

Indicador	Valor (SIH/SUS · RJ · 2025)
Internações (AIHs aprovadas)	926.136
Valores aprovados	R\$ 1,71 bilhão
Permanência média	5,3 dias
Mortalidade hospitalar	6,39%
Capítulo CID-10 com mais internações	Gravidez, parto e puerpério (144.260)
Município com mais internações (residência)	Rio de Janeiro (288.172)

Fonte: base aberta DS-01 do projeto — SIH/SUS · DATASUS, competências 2025-01 a 2025-12. Elaboração própria (TED 77/2024).

✚ NA PRÁTICA (SUS)

Tudo é público e reutilizável: a **base de dados** (CSV + dicionário + datapackage) está em **github.com/RaulAraujoSilva/ted77-sih-rj-dados-abertos** e o **painel interativo** está no portal do projeto. Uma secretaria pode replicar o pipeline para a sua UF trocando poucas linhas do código aberto que acompanha a base.

4.3 A agenda à frente

A publicação aponta quatro direções de evolução: **escalabilidade** (arquiteturas em nuvem, atualização quase em tempo real); **qualidade e padronização** (identificadores unificados e alinhamento a padrões internacionais como OMOP e HL7 FHIR); **experiência do usuário** (interfaces móveis e consultas em linguagem natural); e **inteligência artificial** — modelos preditivos para tendências, anomalias e riscos, sempre com explicabilidade para sustentar a confiança do gestor.

⚠ ATENÇÃO

Painel não substitui julgamento. Indicadores derivados de dados administrativos carregam as regras do faturamento (ex.: a AIH aproxima, mas não é idêntica a "uma internação"). Use os painéis para **orientar perguntas e priorizar investigações** — e documente sempre a fonte e a competência dos dados.

PRATIQUE AGORA · M4Q1

Segundo a publicação, o principal ganho de tempo dos painéis integrados para o gestor é:

- Eliminar a necessidade de limpeza de dados.
- Detectar tendências, como surtos, em minutos — tarefa que antes levava dias com tabelas estáticas.
- Substituir o registro dos dados nos sistemas de origem.
- Dispensar a vinculação probabilística de registros.

Gabarito: B. É a síntese do impacto: "minutos, e não dias" para detectar tendências e mudanças no uso dos serviços. As demais alternativas confundem o papel do painel (que consome dados tratados — não elimina o tratamento nem o registro de origem).

EM RESUMO · MÓDULO 4

- Painéis de BI entregam interatividade: filtros, séries e drill-down sobre o cubo OLAP;
- O ganho central: tendências detectadas em minutos, não em dias;
- O projeto provou o caminho com dados reais: 926 mil internações do RJ em 2025, abertas e navegáveis;
- Futuro: nuvem e tempo quase real, OMOP/FHIR, interfaces conversacionais e IA explicável.

PARA SE APROFUNDAR

GAZZARATA, R. et al. **HL7 Fast Healthcare Interoperability Resources (HL7 FHIR) in digital healthcare ecosystems for chronic disease management: scoping review**. International Journal of Medical Informatics, 2024.

Citada na publicação: panorama do padrão FHIR, o caminho internacional para a interoperabilidade que o Brasil persegue com a RNDS.

Síntese do percurso

Esta apostila percorreu, em quatro módulos, o argumento central da publicação *Building Health Management Dashboards with DATASUS Public Data*:

1. **O tesouro existe:** o DATASUS guarda um dos maiores acervos públicos de dados de saúde do mundo, alimentado por um sistema que atende mais de 75% da população (Módulo 1);
2. **Mas está trancado:** sistemas criados em separado, sem identificador único de paciente, fragmentam a análise — e o TabNet entrega apenas tabelas estáticas (Módulo 2);
3. **Existe um caminho aberto:** extração programática (PySUS), limpeza, vinculação probabilística (Fellegi-Sunter) e organização OLAP (Módulo 3);
4. **E o resultado transforma a gestão:** painéis interativos que detectam tendências em minutos — demonstrados neste projeto com os dados reais do RJ em 2025, publicados em formato aberto (Módulo 4).

O convite final é prático: **explore o painel, baixe a base, reutilize o código**. O dado é público — e o conhecimento gerado a partir dele também deve ser.

Glossário

AIH — Autorização de Internação Hospitalar

Documento que autoriza e fatura a internação no SUS; unidade de registro do SIH e aproximação usual de "uma internação".

BI — Business Intelligence

Conjunto de ferramentas e práticas para transformar dados em painéis e análises de apoio à decisão.

CID-10

Classificação Internacional de Doenças (10ª revisão), usada para codificar diagnósticos; organiza-se em 22 capítulos.

CNES

Cadastro Nacional de Estabelecimentos de Saúde.

DATASUS

Departamento de informática do SUS; mantém e dissemina os sistemas nacionais de informação em saúde.

Drill-down

Detalhamento progressivo de um indicador (do estado ao município, do ano ao mês).

ETL

Extract, Transform, Load — o fluxo de extração, transformação e carga que alimenta o armazém analítico.

Fellegi-Sunter

Modelo estatístico clássico de vinculação probabilística de registros.

HL7 FHIR

Padrão internacional para troca de informações em saúde; base técnica de interoperabilidade (no Brasil, adotado pela RNDS).

OLAP

Processamento analítico on-line: organização dos dados em fatos e dimensões para consultas multidimensionais rápidas.

OMOP

Modelo de dados internacional que padroniza bases de saúde para pesquisa colaborativa.

PySUS

Pacote Python de código aberto para acesso programático aos arquivos do DATASUS.

Record linkage (vinculação de registros)

Técnicas para decidir se registros de bases diferentes pertencem à mesma pessoa.

SIA / SIH / SIM / SINAN / SINASC / SI-PNI

Sistemas nacionais: ambulatorial, hospitalar, mortalidade, agravos de notificação, nascidos vivos e imunizações, respectivamente.

TabNet

Tabulador web do DATASUS para consultas com tabelas-resumo estáticas.

Referências

- ALVES, L. F.; SILVA, R. A.; OLIVEIRA, D. Z. W.; RODRIGUES, L. E. M.; SEIXAS, F. L.; SANTOS, A. B. **Building Health Management Dashboards with DATASUS Public Data**. IEEE INDUSCON. Universidade Federal Fluminense. Pesquisa apoiada pelo TED nº 77/2024 (SEIDIGI/Ministério da Saúde).
- ALI, M. S. et al. Administrative data linkage in Brazil: potentials for health technology assessment. **Frontiers in Pharmacology**, v. 10, p. 984, 2019.
- ICHIHARA, M. Y.; ALMEIDA, B.; BARRETO, M. L. CIDACS: Brazil's Center for Data and Knowledge Integration for Health. **International Journal of Population Data Science**, v. 6, n. 1, 2021.
- JUNIOR, E. P. P. et al. Integrating real-world data from Brazil and Pakistan into the OMOP common data model and standardized health analytics framework to characterize COVID-19 in the Global South. **JAMIA**, v. 30, n. 4, p. 643-655, 2023.
- GAZZARATA, R. et al. HL7 FHIR in digital healthcare ecosystems for chronic disease management: scoping review. **International Journal of Medical Informatics**, 2024.
- FREIRE, S. M.; SOUZA, R. C.; ALMEIDA, R. T. Integrating Brazilian health information systems in order to support the building of data warehouses. **Research on Biomedical Engineering**, v. 31, p. 196-207, 2015.
- TED 77/2024 — Transformação Digital do SUS (UFF/FEC/SEIDIGI-MS). **Internações hospitalares do SUS no Rio de Janeiro — 2025 (SIH/SUS)**, base de dados aberta, v1.0.0, 2026. Disponível em: github.com/RaulAraujoSilva/ted77-sih-rj-dados-abertos.

Coleção de Divulgação Científica · TED 77/2024 — Transformação Digital do SUS
Universidade Federal Fluminense · Fundação Euclides da Cunha · Ministério da Saúde (SEIDIGI)